

Plan de trabajo - Entrega 1 (v2)

ICS2133 - Fundamentos de Simulacion de Sistemas Estocasticos | Proyecto: Markov Fitness Club |
Fecha de entrega: viernes 25 de septiembre

1. La idea central

Las tres variables continuas de la Parte 1 (duracion de fuerza S_{ij}^F , duracion de cardio S_i^C y tiempo de reparacion S^{rep}) se analizan con el mismo procedimiento: depurar $\rightarrow$ describir $\rightarrow$ proponer candidatas $\rightarrow$ estimar parametros $\rightarrow$ test de bondad de ajuste $\rightarrow$ elegir modelo. Por eso ese codigo se escribe **una sola vez** y las 3 lo usan igual, en vez de que cada una programe su propia version de la limpieza y del ajuste. Esto evita justo el riesgo que nos preocupa: que dos personas depuren la misma columna con criterios levemente distintos y el informe quede inconsistente entre secciones.

R_i (tipo de rutina) es la excepcion: es categorica, no pasa por ese pipeline. Ahi solo se estiman proporciones y, si corresponde separar por perfil, se aplica un test de homogeneidad (no un test de bondad de ajuste continuo).

2. Paso 1: sesion inicial conjunta (hoy, ~4 h)

Las 3 juntas. Esta sesion define los criterios de los que dependen todos los analisis posteriores, por eso no se delega a una sola persona.

- **El diccionario primero (45 min).** Leer diccionario_logs.xlsx entre las 3 y anotar que significa cada columna y cada codigo de evento, antes de tocar los datos.
- **Inventario de los dos archivos (30 min).** Cuantas filas tiene cada uno, cuantas jornadas distintas, que tipos de evento existen y cuantos hay de cada uno.
- **Revision de calidad (1 h).** Por columna: cuantos vacios hay y en que tipos de evento aparecen (la mayoría son estructurales, ej. la duracion de cardio esta vacia en filas de ejercicios de fuerza, eso es normal). Despues buscar lo que si es basura: duraciones negativas o cero, valores absurdos, filas duplicadas, actividades que nunca terminan.
- **Escribir los criterios de depuracion (30 min).** Que filas se botan y por que, en un parrafo. Esto se evalua directamente en la pregunta 1a del enunciado, no puede quedar solo dentro del codigo.
- **Listar candidatos de agrupacion (1 h).** Para cada variable, de que podria depender: fuerza por tipo de maquina o categoria, cardio por perfil de usuario, reparacion por tipo de maquina. Graficar histogramas separados por candidato. No hay que cerrar la decision hoy, basta con dejar la lista de hipotesis a probar.
- **Acordar convenciones (15 min).** Donde vive el codigo (repositorio o carpeta compartida), semillas fijas para la simulacion, y un formato unico de tabla de resultados: distribucion, parametros estimados, estadistico, p-value, conclusion.

Que debe quedar al salir de la sesion: un script de carga y limpieza que las 3 usen igual, y una pagina escrita con los criterios de depuracion y las hipotesis de agrupacion. Con eso el resto se trabaja en paralelo sin pisarse.

Dos reglas del enunciado que no se pueden pasar por alto: los dos logs son independientes (day_id y historical_day no representan las mismas jornadas, no se cruzan) y los campos vacios no son ceros, corresponden a variables que no aplican a ese tipo de evento.

Resumen de asignacion

Persona	Tareas asignadas	Carga estimada
---------	------------------	----------------

Persona 1	Parte 1: S_{ij}^F (duracion de fuerza) + R_i (tipo de rutina)	~14 h
Persona 2	Modulo compartido de limpieza y ajuste + S_i^C (cardio) + S^{rep} (reparacion)	~13 h
Persona 3	Parte 2 completa (proceso de llegada) + Parte 3 completa (simulacion)	~15-16 h

Medido en horas (no en puntos del rubric) porque es lo que realmente refleja la carga de trabajo: 27 de los 60 puntos de la pauta no equivalen a 27 horas de esfuerzo. Con esta metrica las 3 cargas quedan razonablemente parejas (13-16 h).

PERSONA 1

Fuerza + Tipo de rutina | ~14 h

1. Extraccion de los datos (1,5 h)

- Filtrar el log operacional para quedarse solo con los ejercicios de fuerza completados (el enunciado pide la duracion efectiva; en el registro tambien hay intentos que no terminaron). Dejar explicito el criterio usado.

2. Analisis exploratorio global (2 h)

- Estadisticas descriptivas, histograma, boxplot. Revisar localizacion, dispersion, asimetria, colas, multimodalidad y atipicos. Si aparece multimodalidad, es señal fuerte de que hay que separar grupos.

3. Decision de agrupacion (2,5 h)

- Comparar la duracion por tipo de maquina y por categoria (empuje, jalon, piernas, multifuncional). Boxplots comparativos mas un test no parametrico de diferencias entre grupos (ej. Kruskal-Wallis). Concluir con que estructura se sigue: todo junto, por categoria o por maquina, justificando con evidencia visual y estadistica.

4. Ajuste de candidatas (2,5 h)

- Para cada grupo definido, proponer 2 a 3 distribuciones compatibles con el soporte de la variable (positiva y continua, ej. Gamma, Lognormal, Weibull) y estimar sus parametros. Usar el modulo compartido de Persona 2.

5. Tests de bondad de ajuste y seleccion (2,5 h)

- Test de bondad de ajuste (Kolmogorov-Smirnov o Anderson-Darling) con $\alpha = 0,05$ para cada candidata. Reportar estadistico, p-value y conclusion, mas QQ-plot. Elegir un modelo por grupo y dejar explicita la distribucion con sus parametros.

6. Tipo de rutina R_i (1,5 h)

- Una observacion por visita. Estimar la proporcion de cada uno de los tipos de rutina. Evaluar si conviene separar por perfil de usuario mediante un test de homogeneidad (ej. chi-cuadrado) con $\alpha = 0,05$. Reportar las probabilidades estimadas para la estructura elegida.

7. Redaccion (2 h)

- Sus partes de las secciones 1a, 1b y 1c del informe (fuerza y tipo de rutina).

Nota sobre dependencias: Los pasos 1 a 3 (extraccion y exploratorio) no dependen del modulo de Persona 2, se puede partir de inmediato. Los pasos 4 y 5 (ajuste y test) si usan ese modulo, por eso van despues en el orden de la semana.

PERSONA 2

Codigo base + Cardio + Reparacion | ~13 h

1. Consolidar el script de carga y limpieza (2 h) - Prioridad: entregar el viernes 12 sep

- Tomar lo que salio de la sesion conjunta y dejarlo como un script limpio y reutilizable: carga los dos archivos, aplica los criterios acordados y expone funciones para extraer el subconjunto de cada variable. Persona 1 y Persona 3 dependen de esto para la etapa de ajuste.

2. Escribir el modulo de ajuste y test (3,5 h) - Prioridad: entregar el lunes 14 sep

- Funciones que reciben un vector de datos y devuelven: estadisticas descriptivas, histograma con las densidades ajustadas superpuestas, estimacion de parametros de las candidatas, estadistico y p-value del test de bondad, y QQ-plot. La salida debe calzar directamente con el formato de tabla acordado en la sesion inicial.
- Entregar primero una version minima funcional 1 a 2 dias antes de la fecha limite, para que Persona 1 y Persona 3 alcancen a probarla y avisar si algo no calza antes de que sea urgente.

3. Tiempo de reparacion S^{rep} (2 h)

- Es la variable mas simple: viene en su propio archivo (log_reparaciones_historico.csv), una fila por reparacion y la duracion ya calculada. Exploratorio, evaluar si se separa por tipo de maquina, ajustar candidatas y testear con el modulo propio.

4. Duracion de cardio S_i^C (3 h)

- Filtrar el log operacional para quedarse solo con las sesiones de cardio realizadas. Exploratorio, evaluar agrupacion por perfil de usuario, ajustar y testear.

5. Tablas y figuras del informe (1,5 h)

- Unificar el formato de todo lo que produzcan las 3, para que el informe no se lea como escrito por tres personas distintas.

6. Redaccion (1,5 h)

- Sus dos variables (cardio y reparacion) dentro de las secciones 1a, 1b y 1c.

Nota sobre dependencias: Los pasos 1 y 2 tienen fecha dura porque Persona 1 y Persona 3 dependen de ellos para cerrar sus ajustes. Es el unico cuello de botella real del plan; la entrega adelantada de una version minima (paso 2) es la forma de amortiguarlo.

PERSONA 3

Proceso de llegada + Simulacion | ~15-16 h

1. Extraccion y construccion de conteos (2 h)

- Quedarse con los intentos de llegada al acceso principal (son los intentos, no las admisiones: incluyen a los rechazados). Construir los conteos por intervalo de tiempo dentro de la jornada, con una discretizacion razonable.

2. Analisis exploratorio (2 h)

- Perfil de llegadas a lo largo del dia: horas peak, si la tasa es constante o cambia sistematicamente. Revisar diferencias entre grupos de usuarios. Proponer una estructura de analisis consistente con lo observado.

3. Tests de hipotesis (3 h)

- Formular y correr los contrastes que exigen las propiedades del proceso candidato: distribucion de los conteos, estacionariedad o cambio sistematico a lo largo de la jornada, y diferencias entre grupos. Reportar hipotesis, estadistico, p-value y conclusion de cada uno, con $\alpha = 0,05$.

4. Estimacion del modelo (2 h)

- Proponer el proceso y estimar todos sus parametros: estructura temporal (tasa por tramos o funcion de intensidad) y cualquier diferenciacion entre tipos de usuario, justificada con la evidencia obtenida.

5. Parte 3a. Generador de llegadas (2,5 h)

- Implementar en Python el procedimiento de generacion y describir como incorpora la estructura y los parametros estimados. Sin el codigo, esta parte vale 0 puntos, sin importar lo que diga el informe.

6. Parte 3b. Validacion (2,5 h)

- Simular 200 jornadas y comparar los patrones obtenidos con los historicos, al mismo nivel de agregacion definido en la Parte 2. Medidas resumen, graficos comparativos, analisis de las diferencias y conclusion.

7. Redaccion (2 h)

- Secciones completas de las Partes 2 y 3.

Nota sobre dependencias: No depende del modulo de Persona 2 (la Parte 2 no ajusta las variables continuas de la Parte 1, usa sus propios tests de conteo/hipotesis). Es el frente conceptualmente mas dificil y el mas facil de subestimar: conviene partir apenas termine la sesion conjunta.

3. Calendario

Fecha	Poco
Jue 11 sep	Sesion conjunta (Paso 1), ~4 h.
Vie 12 sep	Persona 2 entrega el script de carga y limpieza. Persona 1 y Persona 3 avanzan con extraccion y exploratorio (no depende del script).
Sab 13 - Lun 14 sep	Persona 2 entrega el modulo de ajuste y test (version minima el 13, version final el 14).
Mar 15 sep	Punto de control, 30 min: cada una cuenta que encontro en su exploratorio y si algun hallazgo obliga a ajustar los criterios de depuracion.
Mie 16 - Mar 22 sep	Ajustes, tests de bondad de ajuste e hipotesis, estimacion del proceso de llegada y codigo de la Parte 3.
Mie 23 - Jue 24 sep	Redaccion integrada, figuras, revision cruzada del informe completo.
Vie 25 sep	Entrega en Canvas: informe en PDF + .zip de codigo + Declaracion de Uso de IA.

Los ultimos dos dias son solo para escribir. El error tipico es llegar al 23 con todos los resultados listos y sin informe redactado.

4. Coordinacion

Despues de la sesion inicial, las 3 lineas de trabajo son independientes: las 4 cantidades de la Parte 1 no dependen unas de otras, y la Parte 2 no necesita ningun resultado de la Parte 1. Solo hay dos puntos de contacto reales:

- **El modulo de Persona 2.** Mientras no exista, Persona 1 y Persona 3 no pueden cerrar sus ajustes de distribucion (aunque si pueden avanzar en la extraccion y el exploratorio, que no lo necesitan). Por eso tiene fecha propia y una version minima adelantada.
- **Hallazgos en los datos.** Si alguien encuentra algo que obliga a botar filas o reinterpretar un campo, cambia el trabajo de las 3. Para eso esta el punto de control del 15 de septiembre.

La redaccion final es conjunta: no basta con pegar tres secciones, alguien tiene que leer el documento completo de corrido para que no queden criterios contradictorios entre partes.

Antes de subir

- Las 4 variables de la Parte 1 usan $\alpha = 0,05$ y el mismo criterio de depuracion acordado en la sesion inicial.
- Ningun analisis cruzo `day_id` (log operacional) con `historical_day` (log de reparaciones).
- Cada test de bondad de ajuste o de hipotesis reporta estadistico, p-value y conclusion explicita.
- El codigo de la Parte 3 (simulacion de llegadas) esta incluido en el .zip; sin esto la Parte 3 vale 0.
- Informe en PDF, maximo 20 paginas de contenido, sin contar portada, indice ni anexos.
- .zip con todo el codigo Python subido por separado; el informe no va dentro del .zip.
- Archivos con nombres explicativos y una nota breve en el informe de como ejecutar el codigo.
- Verificar que cada numero reportado en el informe salga efectivamente del codigo: si no concuerdan, esa pregunta vale 0.
- Declaracion de Uso de IA completada y adjunta. No adjuntarla son 10 puntos menos.
- Responder el formulario de evaluacion de pares dentro del plazo.